AI 教練的小小圖書館

CarbonGuide RAG 後台白話圖解



你問一個問題。
它先翻資料，再把找到的內容說給你聽。

如果找不到能用的資料，它會說：「這次還不能回答。」
管理員的工作，就是把書整理好，再檢查它有沒有說對。

> 一起讀：先看故事和圖，再看每頁的小提醒。圖書館、書卡和書包都是比喻；真正做事的是電腦程式。

繁體中文白話版 1.0 | 2026-10-28
依原技術文件 1.1 與本機規劃改寫。狀態沿用文件紀錄，沒有重新查詢線上系統。

先看懂這座圖書館

先知道它做什麼，再慢慢看每一步。

放進資料
把書交給管理員

→

整理與找書
保留能核對的內容

→

回答與檢查
說明答案從哪裡來

我們希望 AI 教練能回答氣候與生活相關的問題。RAG 就是這種「先找指定資料，再整理答案」的做法。

現在走到哪裡了？

可以準備、可以試問
管理員有整理資料、測試問題和查看紀錄的後台。試問要有可用的輪次與額度。

還在等人工檢查
原文件記錄：候選內容尚未人工核准，還沒有啟用的知識版本。

還沒開放給 App 使用者
公開回答服務關閉；Flutter App 尚未接上這套流程。

閱讀地圖：第 3-8 頁看它怎麼工作；第 9-15 頁看管理員怎麼把關；第 16 頁看未來計畫；第 17-18 頁查名詞和來源。

誰在幫忙做事？

想像一座有櫃台、書櫃和幫手的小圖書館。

櫃台：你看得到的畫面

你在這裡按按鈕、上傳文件、輸入問題。工程師叫它「前端」。

管理室：檢查規則

確認誰來了、能做什麼、用哪版資料、還有多少額度。這些由「後端」檢查。

書櫃與登記簿：保存東西

書櫃保存 PDF 原檔；登記簿記住文件名稱、段落、版本和費用。它們叫 Storage 和資料庫。

整理幫手與說話幫手

整理程式讀文件、辨認字；Gemini 模型幫忙建立搜尋線索，也依找到的資料整理回答。

前端畫面、後端規則、資料庫和模型各有工作。看到漂亮的畫面，不代表裡面的資料已經檢查完。

> 真正決定能不能讀資料、送問題或花錢的是後端規則。只把畫面上的按鈕藏起來，保護還不夠。

一本 PDF 怎麼變成能找的書？

上傳只是把書送到門口，後面還有工作。

1 **收好原本的書**

保存原檔，也留下像指紋一樣的記號，確認後來讀到的是同一份。

2 **把字和表格整理出來**

Docling 整理文件；掃描頁需要時用 OCR 認字。頁碼、表格標題也要留下。

3 **分成能找到的小段落**

像在書裡放書籤。每段都記住出自哪份文件、哪一頁。原本的書仍保留。

4 **做好找書卡**

把段落轉成一串數字，方便電腦找意思相近的內容。這一步叫 embedding。

> 卡片做完，狀態可以是 ready，意思是「準備好了」。還要有人檢查內容。它不表示「已核准」或「大家都能用了」。

目前文件解析與文件向量準備由維護者執行本機工具。上傳不會自動啟動雲端解析。認不清的字與數字要查原文，有問題的段落可以隔離，不能自己猜著補。

它怎麼找到對的那一頁？

一邊找相同的詞，一邊找接近的意思。

小朋友問：「怎麼讓吃不完的飯變少？」

第一位找書員：看詞語

找出有相關詞語的段落，例如「食物」或「浪費」。這叫關鍵字搜尋。

第二位找書員：看意思

就算用字不同，也試著找意思相近的段落，例如「減少剩食」。這叫語意搜尋。

兩份候選清單

詞語與意思各找一次

→

合併、挑選

排順序、去掉重複

→

拿完整證據

連同表格與條件來看

找書卡只幫忙找位置。真正交給回答模型的，是找到的文字。不能只拿表格裡的一個數字，就忘記它的單位和適用條件。

> 它只找這次指定版本裡可用的資料。這個流程不會自己跑去整個網路隨便找答案，也不會把上傳的書變成一個重新訓練的新模型。

本頁的問題和詞語是解說用例子，沒有實際送出試問。

一個問題進來後，發生什麼事？

有些問題走短路線，有些要先翻書。

先確認身份、試問輪次、資料版本和額度。
再確認問題是不是這個系統能處理的。

路線 A：剛好有整理好的問答卡

如果完全符合這版收錄的 QA 問題，就使用卡片裡有來源的答案。不是問法有點像就一定命中。

路線 B：指定了允許的計算

交給固定計算工具，用選定的數值與規則運算，不請說話模型自己心算。

路線 C：需要翻資料

先找證據，再請模型整理文字。送出前，程式還要檢查引用、數字和單位。

檢查入口
身份、版本、額度

→

選擇路線
問答卡、計算或翻書

→

保存結果
回答、拒答或未完成

每題都是一次獨立提問。目前沒有跨題聊天記憶；不要假設上一題說過的條件會自動帶到下一題。

為什麼有時候它說「不能回答」？

找到一些字，還不一定能說出可靠的答案。

老師會問：「你這句話，是從哪一頁看來的？」

模型整理答案時，要替每個說法選一段原文。程式再把來源、頁碼和摘錄接好。這些讓你能回去查的線索，叫「引用」。

找不到足夠證據

可能是這一版沒放那份資料，或找到的內容不夠相關。它會保守地拒答。

答案沒通過檢查

模型可能已經寫了文字，但引用、數字或單位不合規則。畫面仍會顯示拒答。

檢查本身也有限制

例如原文寫 40 years，答案改成 40 年，現行逐字規則也可能擋下。拒答不一定表示原文沒有答案。

> 程式可以比對文字，卻不能保證整句話真的講對了。人還要檢查：這段來源支持這個說法嗎？是不是少了日期、地區或其他條件？

找不到資料時，系統不會暗中再叫另一個模型修答案。目前候選的問題改寫功能也關閉。

問答卡、說話方式、規則小紙條

這三樣都可以整理成草稿，但用途不同。

通用 QA：整理好的問答卡

常見問題可以先寫好答案，也附上支持答案的原文。只有被這一版選進去的卡片才會使用。

人格：說話的方式

像同一位老師，可以說得溫柔，也可以說得簡短。語氣改了，資料的事實不能跟著亂變。

提示詞：給模型的小紙條

告訴模型怎麼整理回答。它能影響表達方式，不能取消後端的權限、來源與花費限制。

按下儲存，為什麼答案沒變？

儲存只是把新草稿留下。試問還在讀原本的版本，就仍然使用原本的內容。要建立新版本，並讓新的試問輪次選用它。

> 後台有些欄位還保留著，但不控制目前 v1 的行為。例如拒答草稿不會直接取代目前固定的拒答文字；要看欄位旁的說明。

把這次要用的資料，裝進書包

封好的書包，就是一個固定的知識版本。

書包裡裝著選定的文件段落、問答卡、人格、提示詞、計算資料和設定。電腦叫這個固定組合「快照」。

整理草稿
還可以修改

→

封好 A 書包
固定本次內容與設定

→

拿 A 來試問
記住答案用過哪一版

發現錯字：做一個 B 書包

已固定的 A 不直接改掉。這樣回頭查舊答案時，才知道它當時看見什麼。

審核與發布：檢查後選用

人要檢查這個確切版本，也要符合評測門檻，才能把它設成啟用版本。

回滾：選回符合條件的舊書包

只能選曾發布、仍符合審核與來源條件的版本；新版本與紀錄不因此刪掉。

有兩個不同開關：「選用哪一版知識」和「讓一般使用者來問」。發布版本不會自動開放 App。

後台的七個抽屜

你要做哪件事，就打開對應的抽屜。

文件與段落	看原檔、處理進度、頁碼和文字；找出要修正的內容。
通用 QA	整理常見問題、答案與來源。
人格與提示詞	調整說話方式和給模型的說明。
試問	在有限輪次裡問問題，也可以執行固定題庫的評測。
知識版本	裝好書包，看報告，再做審核、發布或回滾。
互動紀錄	查看以前的問題、回答、引用和處理過程。完整新版紀錄限 owner。
RAG 設定	整理搜尋與計算草稿，查看預算、成本和運作狀態。

> 先看文件品質，再整理草稿、建立版本、試問和檢查。只是打開詳情、換頁或讀舊紀錄，不會重新呼叫模型。

詳情可以關閉後回到列表。尚未儲存就關閉，編輯會捨棄；儲存中暫時不能關閉。

碰到數字，交給計算機

先確認規則和單位，再開始算。

說話幫手很會寫句子，計算工作則交給固定工具。管理員先放入有來源、適用日期和地區的數值，工具再照規則計算。

係數：每一份對應多少

像「有幾盒」乘上「每盒幾顆」，就能算出總數。正式碳排計算也要確認活動量、係數和單位能配在一起。

電費：不同階梯，價錢可能不同

像買東西時不同段有不同價格。要分別算原本用電和改善後用電的費用，再算差多少。不能隨便只乘一個價格。

目前電費工具算的是哪一種？

原文件記錄的是歷史測試資料：2025 年 10-12 月的非夏月住宅流動電費，限一個或兩個完整月份。它不包含基本費、稅和其他附加費，也不能當成完整帳單。

> 原始係數表裡有數字，不表示那些數字已核准可用。人還要查年份、地區、單位和來源。水費、時間電價與車型油耗計算留待後續。

請幫手工作，要顧好零用錢

先留錢、估花費、看帳單，是三件事。

預留：先把一部分錢留住

就像買東西前，先把可能需要的錢放到一旁。這是防止超支，還不是已經付掉的金額。

估算：按收到的用量來算

拿到模型的使用量，才能依記錄的單價估計。資料沒收到，就保留「未知」。

帳單：確認供應商實際收多少

最後用 Google 的使用費帳單核對。帳戶儲值多少，不代表這次已經花多少。

本輪文件記錄的模型預算上限是 US$5。準備文件、試問和評測共用這個上限；每個試問輪次還有題數、期限和自己的限制。

> 如果送出後卡住，先查同一題的紀錄。未知不等於免費，也不表示工作沒做。不要連按重送，或另開一個預算把原本限制繞過去。

停止輪次或預算活動，可以擋住後續呼叫；已開始的工作仍可能完成。US$5 是本輪模型活動上限，不包含未建置的雲端主機、儲存和流量費。

誰有鑰匙？誰看得到紀錄？

知道圖書館在哪裡，不等於可以打開每個櫃子。

進門也要核對身份

預覽站有 Vercel 的保護，後台另有 Google 管理員登入與角色檢查。目前沿用既有白名單。

每個角色的權限不同

owner 管理重要的預算、審核與發布；editor 在授權範圍整理資料和試問；viewer 只能讀允許的資料。

高權限鑰匙留在受控地方

瀏覽器有公開連線資訊，但它不等於管理員鑰匙。模型金鑰和伺服器高權限金鑰不能放到網頁或文件。

書放在私有櫃子，就完全不會送出去嗎？

仍有部分文字要交給 Google 模型處理。建立找書卡會送出選定段落；回答時會送出問題、相關設定與找到的證據。私有保存和外部處理是兩件事。

> 新版問答正文和詳細流程限權保留 30 天；完整紀錄限 owner 讀取。到期不表示原始文件、知識版本和費用帳也全部刪光。

考卷過了，還要老師看嗎？

要。電腦檢查和人的判斷，各有工作。

練習卷：找出哪裡要改

development 題庫幫忙發現問題。修改後，仍要保留舊結果。

驗收卷：另外一份固定考卷

acceptance 題庫獨立保留。不能看完分數才改標準答案，或把失敗題刪掉。

老師複查：答案真的合理嗎？

人要看原文、日期、地區、表格和語意。引用對得上，還要確認它真的支持答案。

原文件留下的成績

開發題通過 19 / 20 題；驗收題通過 36 / 40 題。這是以前那次固定測試的結果，本次沒有重考。候選內容仍待人工審閱，不能說已經完成公開上線驗收。

> 「前五名找到需要的來源」「引用文字有效」「這題答得對」和「人工同意發布」是不同檢查。某一項分數高，不表示其他項也都通過。

發布還須符合指定版本的多項門檻與有效人工核准。模擬畫面測試只證明那個模擬情境，不能代替真實登入、模型連線或人工內容驗收。

卡住時，先找哪張小紙條？

每次試問都有自己的編號和紀錄。

資料上傳了，還不能問	先看解析和找書卡是否做好；再看這次版本有沒有選入。
改過草稿，答案沒變	看試問輪次用的是哪一版。新草稿需要裝進新書包。
明明有原文，卻被拒答	檢查來源是否在本版、搜尋結果夠不夠，以及引用或數字在哪一步沒過。
一直轉圈，結果未知	保留本次編號，讀同一筆紀錄。關頁面不代表後端已取消。
找不到以前的完整回答	看是否有 owner 權限、是否超過 30 天；舊版沒保存的正文不能還原。
抓網址失敗	留下原因，交給維護者查。文件裡有網址，不代表網站內容已抓回來。

> 紀錄像工作日記：這次做了哪一步、哪一步跳過、哪裡失敗、用了多少額度。讀舊日記不會再請模型做一次。

網址匯入只接受允許的 HTTPS 網域並檢查連線安全。不會任意讀取登入後網頁，也不因憑證錯誤就關掉驗證。

以後可以交給雲端幫忙嗎？

可以規劃，但這個雲端解析方案還沒部署。

現在：維護者的電腦來整理

維護者執行本機工具，處理長文件、認字和文件向量準備。

未來構想：遠方電腦接工作單

把整理程式放進固定的工具箱，交給 Cloud Run Jobs。它領一份工作，完成後回報結果。

上傳並登記
先收到工作編號

→

雲端整理
解析、檢查、做找書卡

→

回報與審閱
看進度，再由人把關

可以把它想成送衣服去洗衣店：店家確實收件並開單後，你才不用站在門口等。未來若工作已成功登記，關掉瀏覽器也不會讓工作單消失；上傳中就關閉，則可能還沒送到。

> 還要做好排隊、防止重複領件、失敗處理、權限與費用上限。雲端也會失敗，不保證每次成功；人工審核和版本規則仍要保留。

雲端主機費要另外估算。後端入口負責接單與檢查；耗時的文件整理交給適合的工作程式。本頁是原文件的後續提案，沒有建立新資源。

遇到英文，就翻這一頁

不用背名詞，知道它在故事裡做什麼就好。

RAG	先查指定資料，再依資料整理回答。
Chunk / OCR	chunk 是可查的小段落；OCR 是把圖片裡的字認成文字。
Embedding / profile	embedding 是找書用的數字卡；profile 規定卡片怎麼做，不同規則的卡不能混用。
Snapshot / hash	snapshot 是固定版本；hash 像內容指紋，用來比對是否相同，不能證明內容是真的。
API / RPC	程式約定好的辦事窗口，讓不同部分請對方執行指定工作。
Auth / JWT / RLS	登入確認身份；憑證帶著身份資訊；資料庫還會逐筆檢查可不可以讀或改。
Campaign / round	campaign 管共用預算；round 是指定版本、期限與題數的試問輪次。
Request / trace	request 是一次請求；trace 是這次工作的過程紀錄。
Worker / queue / lease	處理工作的幫手、等待清單，以及暫時領件的資格。領件到期不代表外部工作沒做。

> React 是做畫面的工具；TypeScript 幫忙檢查程式資料型別；Vite 打包網站。Supabase 提供身份、資料與後端服務，Gemini 是外部模型。

數字小抄與這本書的來處

給想多看一點的大人；小朋友可以先跳過。

20 個候選 6 個證據	預設先選最多 20 個候選，再挑最多 6 個完整證據。 不足時少放，不為湊數亂塞。
0.72 / RRF 的 50	0.72 是搜尋相似度門檻，不是 72% 答對率。RRF 的 50 是合併排名的公式常數。
768 / temperature 0	768 是數字卡的數值個數；temperature 0 減少回答隨機性，不保證永遠答對或逐字相同。
Token / 2,048	token 是模型計量文字的單位，不固定等於一個字。回答最多 2,048 output tokens。
20 MiB / 80,000 bytes	前者限制單個上傳原檔；後者限制一題選用的證據文字。它們不是中文字數。

內容依據與閱讀範圍

主要來源：《CarbonGuide RAG 技術文件》1.1，2026-10-28，共 26 頁。每頁下方的「原文件」頁碼可回查。另對照本機《RAG pilot 使用說明》與《RAG 操作說明收尾紀錄》。
原文件記錄的 47 份候選 PDF、9,271 段、36 / 40 與 US$5 都是既有紀錄，沒有在本次重新核對線上狀態。書中的故事與例子只是說明，不是實際模型回答。

查看原技術文件的版本化文字來源

查看操作與部署收尾紀錄

> 這本書幫你理解流程。要操作後台，請配合《RAG 後台使用指南》；要核對程式細節、完整數值與規則，請回到原技術文件。