CARBONGUIDE / ENGINEERING DOCUMENTATION

RAG 技術文件
AI 氣候教練管理系統

繁體中文版 | 文件版本 1.1 | 2026-10-28
技術原理、名詞白話解釋、現行限制與雲端處理規劃

> 目前提供受保護的管理員 Preview。工程功能與問答紀錄介面已部署；知識內容仍待人工審閱，公開回答服務關閉，Flutter App 尚未接入。

RAG 可以理解為「先從指定資料找證據，再請模型整理回答」。它不會把上傳文件重新訓練成一個新模型；找不到合格證據時，會保存拒答或未完成狀態。

從原始資料到可追溯回答

本系統以私有文件、不可變知識版本、混合檢索及受限模型生成組成 RAG。每次提問固定使用指定版本，保留引用、處理節點及費用紀錄，讓管理者能追查答案的來源與執行過程。

候選文件	候選段落	獨立驗收	核准預算
47 份 PDF	9,271 段	36 / 40	US$5

技術主軸：React + TypeScript、Supabase Auth / Postgres / Storage / Edge Functions、Gemini embedding 與回答、本機 Docling / OCR 解析。

版本基準

原始技術基準：網站 028db7d（原 PDF）、UX f6adae5；後端 270f4f1。
本版補充前端操作說明與 UX，程式提交及部署證據見 rag-admin-guidance-closeout.zh-TW.md。語料、費用與評測數字是歷史快照，不是即時儀表板。

本文件不包含 API 金鑰、登入 token、私人帳號截圖或原始文件全文。工程驗證、機械評測與人工內容核准分開表述。

01 / TECHNICAL REFERENCE

系統範圍與閱讀導覽

先確認交付邊界，再閱讀各層實作。

範圍	目前狀態
管理端工程	私有匯入、候選草稿、版本限定試問、評測、審核 / 發布控制、成本與歷史紀錄已實作。
真實知識內容	47 PDF 全量候選仍在待審狀態；人工核准數 0，啟用版本為空。處理 ready 不代表內容正確。
公開使用者與 App	公開回答關閉；Flutter 接入、一般使用者聊天、相關隱私與刪除帳號流程留待後續。
本文件製作	整理既有程式與驗證紀錄；沒有新增模型呼叫、重跑評測或核准資料。

兩份文件怎麼讀

本技術文件解釋系統如何運作、資料如何連結、模型如何產生受限制的回答。另一份《RAG 後台使用指南》按畫面、按鈕與常見情境說明操作；第一次使用請先讀指南的快速上手。

閱讀路線

先讀「用一個問題理解整套系統」與架構，再讀資料準備、版本、檢索、模型及權限。最後讀成本、驗收和未來雲端解析。PDF 書籤可直接跳到每個主題。

> 工程可運作、機械評測通過、人工內容核准，是三個不同結論。ready 只說明資料準備完成；36/40 的歷史驗收結果仍未達發布門檻。

02 / TECHNICAL REFERENCE

用一個問題理解整套系統

假設管理員問：「如何減少食物浪費？」瀏覽器先把問題交給後端。後端確認管理員身份、輪次、知識版本與額度，再從這個版本的文件找相關段落。模型只能依收到的證據整理回答，後端還要核對引用及數字，最後保存回答與費用紀錄。

名詞	白話意思與本系統的用途
前端 / React	你在 Chrome 看到並操作的畫面。React 用元件組織頁面，讓列表、表單和詳情隨資料更新。
TypeScript / Vite	TypeScript 協助開發時檢查資料型別；Vite 把程式打包成部署到 Vercel 的網站。它們不是回答模型。
後端 / API / Edge Function	API 是前後端約定的呼叫入口；Edge Function 是執行身份檢查、費用預留與問答流程的伺服器程式。
資料庫 / Storage	資料庫保存有欄位的紀錄，例如文件、段落、輪次與費用；Storage 保存 PDF 等檔案本體。
模型 / RAG	Gemini 是處理向量或文字的外部模型。RAG 是先找資料、再回答的一套流程。
CLI / worker	CLI 是維護者在終端機執行的工具；worker 是實際處理一個背景工作的程式。現在解析 worker 在本機。

上傳 ≠ 解析完成 ≠ 向量 ready ≠ 人工核准 ≠ 發布 ≠ 開放 App。這些步驟各自有紀錄，不能跳過前面的檢查。

03 / TECHNICAL REFERENCE

整體架構與信任邊界

網站與後端分屬兩個 repo；瀏覽器不持有伺服器端密鑰。

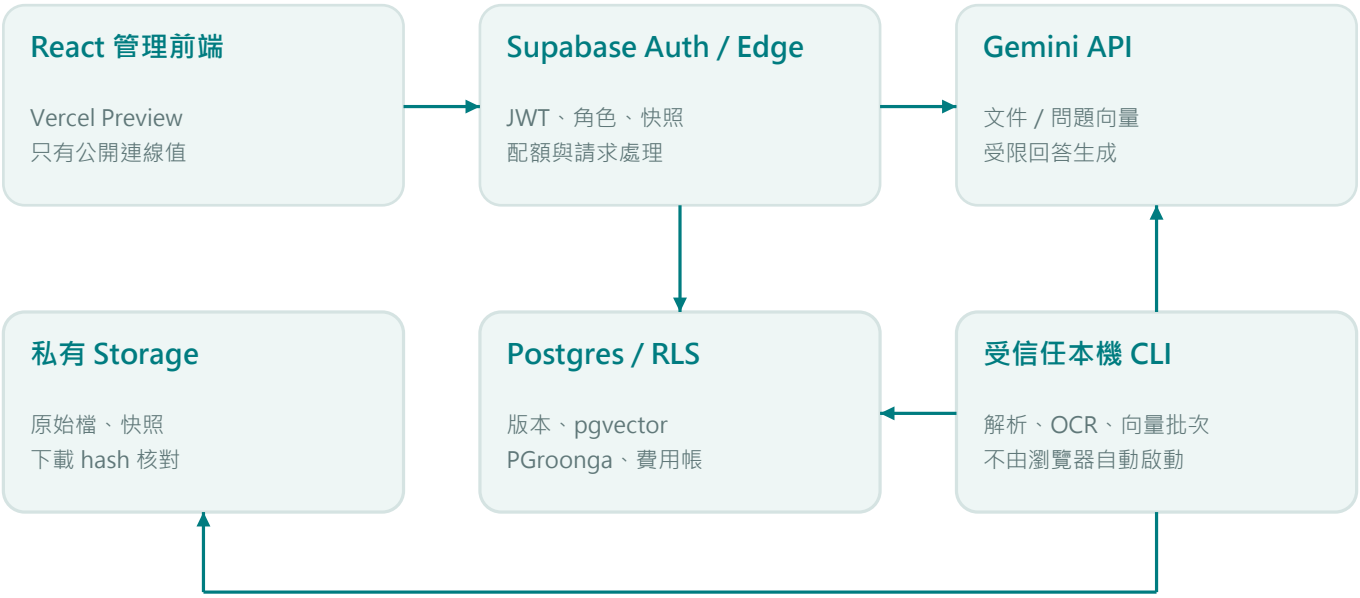


圖 1 主要元件與呼叫方向；直接資料讀取仍受 RLS 限制。

元件	責任與邊界
網站 repo	React 18、TypeScript、Vite、Tailwind 與 supabase-js。/push-admin#rag 經既有登入與角色檢查後載入工作台。
後端 repo	supabase/functions/rag-v1 維護請求、模型、計算與評測；migrations 定義資料契約與 RLS；scripts/rag 執行批次處理。
Supabase	Auth 提供 Google OAuth；Postgres 保存版本與帳本；私有 Storage 保存原始檔；Edge 驗證請求並調用服務。
Gemini 與本機工具	Gemini 接收選定文字與問題；Docling / RapidOCR 在本機解析文件。上傳不會自動啟動雲端解析 worker。

Vercel Authentication 與 Supabase 身份 / 角色檢查各自生效。知道 Preview 網址或持有公開 anon key，不代表擁有資料讀取或付費呼叫權限。

04 / TECHNICAL REFERENCE

來源、解析與向量準備

原始資料保留不變；修訂和隔離產生新的候選身份。

步驟	產物	關鍵檢查
1	原始檔清單	記錄 SHA-256、格式、大小與物理頁；輸出放在來源資料夾之外。
2	私有原始檔	登記、上傳、下載後核對 hash。單檔上限 20 MiB = 20,971,520 bytes。
3	解析 / OCR 產物	Docling、RapidOCR；受監督程序限制時間及記憶體，不執行嵌入內容。長 PDF 可分 12 頁批次處理。
4	完整候選段落	合併前核對 hash、解析契約與全部物理頁；每頁完整且只出現一次，保留章節、表格、引用及頁碼。
5	指定 profile 的向量	有限 campaign 預留後才呼叫 Gemini；精確相同輸入可重用向量，預設每批最多 24 段。
6	ready 候選集合	仍需人工審核。快照只選入已完成向量、同一 profile 且未停用的來源。

品質隔離

遇到未解碼字元，預設拒絕匯入。明確使用隔離模式時，整段排除並記錄原始段落序號、物理頁與 parser 指紋，保留原始解析內容。系統不猜測缺失的負號、上下標或數值，也不把有問題文字悄悄改成看似合理的內容。

URL 快照

只接受列管 HTTPS 網域（IPCC、能源署、自來水公司、國發會）。DNS、公開 IP、固定連線 IP、TLS 與每次轉址均檢查；最多三次轉址、90 秒與 20 MiB。不執行網站 JavaScript、不下載外部圖片，不因憑證錯誤而停用 TLS 驗證。

語料快照：45 份本機原檔 + 8 份 URL 快照 = 53 份私有來源，下載 hash 均核對；候選選入 47 PDF、1,834 頁、9,271 段，另隔離 193 個原始段落。DOCX / HTML 導覽頁及未審 JSON 不等於可用的問答證據。

05 / TECHNICAL REFERENCE

解析與向量：把 PDF 變成可查資料

階段 / 工具	做什麼	不代表什麼
來源	原始 PDF、DOCX、JSON 或允許網站的快照。保留檔名、時間、hash。	文件內出現網址，不等於系統已抓取該網站。
Docling	把文件整理成可處理的文字、章節與表格結構。parser 是解析器的通稱。	它不替資料背書，也不保證表格數字完全正確。
RapidOCR / OCR	把圖片或掃描頁中的字辨認成文字。現行在本機執行。	OCR 可能認錯負號、上下標、單位與欄位。
Chunk / 段落	把解析結果分成可搜尋、可引用的片段，附上來源與物理頁碼。	不是固定一頁一段；同一完整表格可有多個搜尋視角。
Embedding / 向量	把一段文字轉成數字陣列，作為語意搜尋索引。	不是訓練新模型，也不是原文的可讀摘要。
ready	這個候選集合已具備指定 profile 的向量。	不代表人工核准、適用所有問題或已對外發布。

例：PDF 第 7 頁是一張表格。Docling 整理表格欄名與內容；必要時 RapidOCR 認字；品質檢查保留頁碼與完整引用文字，再產生搜尋向量。回答時交給模型的是找到的文字證據，不是只把數字向量當成答案。

20 MiB 是單一原始檔的上傳上限；80,000 bytes 是一題可選證據文字的總上限。兩者管的是不同東西。中文通常每字 3 個 UTF-8 bytes，不能直接把 bytes 當中文字數。

06 / TECHNICAL REFERENCE

資料模型與不可變性

下表為核心邏輯實體；完整欄位與 SQL 約束以後端 migrations 為準。

實體	主要識別 / 內容	不變條件
Document / version	來源、用途、領域、處理及內容狀態	文件身份與處理版本分離，舊版可追溯。
Original / job	sha256、byte_size、stage、attempt、租約	下載後驗證原檔；作業有持久紀錄與重試證據。
Chunk set / chunk	content_hash、ordinal、原文、物理頁、章節	sealed 集合不可就地覆寫；修訂 / 排除建立新集合。
Embedding profile	模型、維度、distance、分段契約	不同模型、維度與契約不能混用向量。
Snapshot / release	manifest_hash、來源集合與完整草稿依賴	固定 QA、人格、prompt、設定、計算資料與模型契約。
Review / activation	指定 hash、verdict、sequence、前一版本	審核對精確版本生效；發布與回滾原子化並保留稽核。
Campaign / round	預算、預留、題數、日上限、期限、版本	共用預算與輪次限制同時檢查，不能重設帳本換取額度。
Request / detail / calls	request ID、state、input、output、trace、usage	問答與詳細流程限權保存 30 天，費用帳與識別紀錄另保留。
Dataset / evaluation	split、dataset hash、snapshot hash、結果	開發 / 驗收分組固定；失敗與未知不得刪除以提高分數。

版本生命週期

原始來源 → 處理 ready → 不可變候選快照 → 固定評測 → 人工核准指定 hash → 發布或駁回。修改草稿只影響下一個快照；停用來源會阻止含該來源的版本發布或回滾。

> 發布版本與開放一般使用者是不同開關。本輪未核准真實內容、未設定 active release；合成發布 / 回滾測試使用 transaction rollback，不能當作真實內容已發布的證據。

07 / TECHNICAL REFERENCE

資料結構：每一層各存什麼

資料結構是資料的分類、欄位及關係。可以想成多張互相連結的清單：文件清單存文件身份，段落清單存可引用內容，問答清單存一次請求。用識別碼相連，避免把同一資料到處複製後失去來源。

關係	例子與用途
文件 → 文件版本 → 段落集合 → 段落	同一文件可有多次解析或修訂；一次選定集合中的段落才構成可用證據。
段落 → 向量 + profile	profile 固定模型、768 維及分段契約；不混用不同規則產生的向量。
快照 → 文件集合 + QA + 設定	把此次使用的內容及參數固定，問答才可追查當時依據。
預算活動 → 試問輪次 → 請求 → 模型呼叫	一題可能有問句 embedding 和回答兩次外呼；費用必須逐次記錄。
題庫 → 評測批次 → 題目請求 → 報告	知道哪組固定題目測了哪個固定版本，失敗也保留。

常見欄位讀法

ID / UUID：一筆資料的唯一識別碼，不是密碼。ordinal：集合內的順序號，修訂後可能重排。SHA-256 / hash：內容指紋，用來比對是否相同；不是加密，也不能證明內容為真。JSON：有欄位名稱的結構化資料。manifest：快照清單，列出本版選入內容與設定。

> 同一段原文在新集合可以有新的 UUID。不能只看文字相同就沿用舊 QA 的段落識別碼；建立新快照會檢查引用是否屬於本次選入集合。

08 / TECHNICAL REFERENCE

不可變、審核、發布與回滾

不可變性表示「已固定的版本不能直接覆寫」。例如版本 A 的第 3 段有錯字，要建立版本 B 的候選集合，版本 A 和它的歷史回答仍保留。這讓你知道以前的回答當時用了什麼，而不是事後看到被改過的證據。

動作	效果與後續
儲存草稿	更新待選入的內容，不回寫已固定快照。
修訂 / 排除段落	產生新集合。保留段落取得新 ID；輸入沒變的向量可沿用，改動輸入則需重新 embedding。
固定快照	鎖定這版內容與設定。每份文件選一集合，向量須完整；QA 引用須屬於選入集合。
人工審核	人核對指定 manifest hash，留下核准或退回及理由。程式檢查不能代替語意審閱。
發布	通過同版驗收及有效人工核准後，切換 active_release_id，表示使用中的知識版本。
回滾	切回曾發布、仍符合條件的版本，不刪新版本或紀錄。
停用目前版本	清除啟用版本指向；不會刪除文件，也不等於停止所有候選試問。

發布知識版本不會打開 service_enabled（一般回答服務開關）。目前 Flutter 尚未接入，不能因後台有發布按鈕就宣稱 App 已能使用。

09 / TECHNICAL REFERENCE

Embedding 與混合檢索

固定 profile 的語意向量，結合中文詞項搜尋與排名融合。

項目	目前實作
Embedding 模型	gemini-embedding-001；768 維；文件 RETRIEVAL_DOCUMENT、問題 RETRIEVAL_QUERY；L2 正規化。
索引性質	Embedding 用於搜尋，不是模型微調；文件不會在每次提問時整批重新向量化。
語意路徑	Postgres pgvector cosine 精確搜尋；只查本次快照選入且仍可用的集合。
詞項路徑	PGroonga 中文關鍵字搜尋；語意與詞項候選按完整脈絡去重。
融合方式	Reciprocal Rank Fusion，k=50。分數是排序量，不是答案正確率或信心百分比。
內容上限	預設檢索 20 個候選、選 6 個脈絡、相似度 0.72；快照上限 50 個候選、12 個脈絡及 80 KB。

排名計算

RRF(d) = Σ 1 / (50 + rank_i(d))
將各路徑的排名轉成可合併權重。短搜尋片段供召回；回答仍使用完整引用脈絡，不能把切片中的孤立數字當成完整證據。

全量效能修正

全量候選曾觸發 8 秒資料庫限制。修正後先排序 ID、脈絡 hash、距離及詞項計數等窄欄位，選出有限候選後才取全文。權限、來源篩選、去重與 RRF k=50 維持一致；比較結果的完整 JSON 相同。

既有單次量測：read-only 查詢 11.154 → 5.677 秒；RPC fixture 13.649 → 6.255 秒。這不是 p95、併發或容量承諾；尚未做負載驗收。原逾時的失敗紀錄與費用預留保留。

官方介面背景：Google Gemini Embeddings 文件 [R6]；此文件固定記錄現行 profile，不宣稱採用最新模型。

10 / TECHNICAL REFERENCE

20、6、0.72、50、12、80 KB 怎麼讀

數值	實際意思
20 個候選（預設）	混合檢索送入後續選擇的候選數上限。不是搜尋整個知識庫時只看 20 段，也不是 20 份 PDF。
6 個脈絡（預設）	從候選中挑最多 6 份完整證據給回答模型；去重、門檻或大小限制可能使結果少於 6。
相似度 0.72（預設）	用向量 cosine 相似度篩選證據。低於門檻就不選；不是答案有 72% 機率正確。
50 / 12（快照上限）	可固定的最大候選數與最大脈絡數。後端會拒絕超出上限的快照，不會因前端填更大而放寬。
80 KB	程式以 80,000 個 UTF-8 bytes 累計選中證據文字；過大的候選略過，不任意截半張表。這不是整個 API 請求大小。

RRF：把兩張搜尋排行榜合併

語意搜尋找「意思接近」；關鍵字搜尋找「詞語相符」。RRF 根據各自名次給分再加總，讓同時在兩邊靠前的內容有機會排更前。本系統 k=50 是公式中的平滑常數，不是取 50 份文件。RRF 分數與 cosine 相似度是兩個不同數字。

示意：找到 20 個候選 → 8 個通過相似度 → 去掉重複證據剩 5 個 → 其中 1 個超出累計大小 → 最後只送 4 個。即使設定 6，也不會為了湊數塞入不合格段落。此例不是實際評測數據。

11 / TECHNICAL REFERENCE

回答流程與引用驗證

每題只使用指定快照；模型輸出仍需伺服器驗證。

01 驗證身份、輪次與不可變快照

先占用題數；模型呼叫另行預留費用

02 服務範圍、允許計算與 QA 完全命中

有確定結果可直接回覆；否則進檢索

03 問題向量與混合檢索

cosine + 中文詞項 + RRF；必要時最多一次改寫

04 依門檻選完整證據並呼叫 Gemini

最多 12 份脈絡、80 KB；模型選原文窗口

05 引用與數量單位驗證、持久化紀錄

通過才回答；不足、失敗及未知各自保留

環節	契約
生成	gemini-3.1-flash-lite · temperature 0 · 單一候選 · 最多 2,048 output tokens · 限制 JSON schema。
證據選擇	模型每句選取伺服器提供的原文窗口 quote_id；伺服器產生引用編號與逐字摘錄，不信任模型自填 offset。
驗證	核對來源 ID、原始 start/end、完整 source slice、數字量級、單位、邊界與輸出大小；不通過則拒答。
改寫	僅證據不足且快照開啟時最多一次；前後數值、貨幣、量級及單位須一致。現行候選關閉改寫。

沒有第二個模型自動修復、隱藏付費重試或跨題聊天記憶；不執行模型產生的 SQL、shell 或任意工具。結構化輸出保證可解析形狀，不保證語意正確 [R7]。

已知限制：數量與單位逐字契約可能拒絕正確翻譯，例如 40 years 改成 40 年。機械引用有效不代表因果、研究適用範圍或回答完整性正確。

12 / TECHNICAL REFERENCE

模型參數與拒答的白話說明

名詞	如何理解
768 維 / L2 正規化	每段文字用 768 個數值表示；正規化把向量長度調成一致，方便以方向比較語意。
Token	模型計量文字的單位；不是固定一個中文字或一個英文單字。供應商回傳用量才能估費。
Temperature 0	減少輸出的隨機性，方便測試；不保證每次逐字相同或答案一定正確。
最多 2,048 output tokens	限制生成長度及成本；不代表每題都會用滿。
JSON schema / 回答契約	規定回覆欄位、型別與可用引用方式。v4 要求每個主張選擇後端提供的原文窗口 ID。
確定性驗證	由程式核對來源 ID、逐字引用、數字與單位。條件沒過就拒答；通過也不證明推論完全正確。

為什麼有模型回覆，畫面仍顯示拒答？

模型可能回了文字，但引用或數字不符合規則。後端會把最終結果改為固定拒答，不把未通過的原始回答當成可提供的答案。互動紀錄顯示已保存的最終回覆，處理原因則供管理員找問題。

現行固定拒答：「目前這個知識版本沒有足夠且可核對的資料回答，請補充問題或交由管理員確認。」完整帳單不支援也使用這段文案，原因碼另外說明服務範圍。RAG 設定中的 fallback_reply 草稿目前不控制 v1 的固定拒答。

13 / TECHNICAL REFERENCE

請求介面與確定性工具

前端 repository 隔離資料讀寫；付費請求由 Edge 統一驗證。

瀏覽器以 supabase.functions.invoke('rag-v1', { body }) 呼叫 action。服務端重新驗證 JWT、角色、輪次、版本、請求內容與預算；前端按鈕可用狀態只是操作提示。下例為介面形狀，識別碼皆為佔位值。

```
{ action: "question", roundId: "<round UUID>",
 requestKey: "<new request UUID>", origin: "query",
 input: { question: "<問題>", persona_id: null, tool_requests: [] } }

讀既有結果：{ action: "request_read", requestId: "<request UUID>" }
```

契約	行為
去重與衝突	相同 request key 與相同輸入不得重複執行；同 key 綁不同內容視為衝突。逾時先讀原 request，不用新 key 盲目重送。
結果狀態	reserved / running 表示未完成；answered、abstained、failed、uncertain 分開呈現，未知不等於未扣費。
QA 與人格	QA 採快照內的完全命中及已驗證引用；人格與 prompt 只影響語氣與回答草稿，不能覆寫後端安全限制。
係數工具	活動量 × 核定係數；核對單位、地區、有效日期及原始引用，採 BigInt 八位小數運算。
電費工具	一或兩個完整月份：分別累進計算改善前後電量，再相減；兩月級距倍增，金額取至分。

計算的適用範圍

工具最多三次，只執行程式列管計算。住宅電費目前是歷史非夏月的流動電費測試資料，限定 2025 年 10-12 月；不包含基本費、稅、附加費、跨季或不完整月份，不可視為完整帳單。水費、時間電價及車型油耗屬後續範圍。

原始 JSON 有 1,164 筆係數，仍須核對年份、單位與有效性。數值可以解析不代表已核准使用。

14 / TECHNICAL REFERENCE

身份、權限與安全控制

維持既有管理員白名單；本輪不擴張 App 或推播權限。

邊界	實作要求
管理員身份	Google OAuth 經 Supabase Auth；後端核對現有 admin_users 與角色。新增管理員需另一項權限變更。
資料存取	RLS / RPC 限制資料列與動作。新版完整問答歷史為 owner-only；editor / viewer 不因前端路由而取得正文。
伺服器操作	付費與寫入動作在服務端核對角色、request ownership、快照、名單、期限及配額；service role 不進瀏覽器。
檔案與網址	私有 bucket、大小 / 格式 / hash 檢查、下載授權；URL 防內網與私有 IP、檢查每次轉址並保留 TLS 驗證。
不受信任內容	文件與模型回應都是資料；React 以文字呈現，無可執行 HTML。引用及工具均有明確白名單與契約。
部署隔離	Vercel Authentication、CSP、X-Frame-Options、noindex；Preview 分支與正式網域分離。

環境設定分類

設定	可放位置
VITE_SUPABASE_URL VITE_SUPABASE_ANON_KEY VITE_RAG_ENABLED VITE_RAG_PROJECT_REF	公開前端 build 值；RAG 值限制在指定 Preview 分支。anon / publishable 值本身不是管理授權。
Gemini key、service-role key	只放後端 secrets 或指定本機環境檔；不得放 VITE_*、Git、PDF、公開 log 或下載產物。

私有 Storage 不代表資料從未離開系統：文件 embedding 會將選定文字送到 Google；回答會送出問題、快照設定與檢索證據。此資料流需納入後續一般使用者接入與隱私審查。

本輪安全驗證針對 RAG 邊界，不是整個既有 Supabase / App / 推播系統稽核。資料庫 RLS 背景可參考官方說明 [R8]。

15 / TECHNICAL REFERENCE

RLS、RPC 與公開 anon key

名詞	白話解釋
Auth / OAuth / JWT	Google OAuth 完成登入授權，Supabase Auth 建立登入身份；JWT 是帶有簽章的身份憑證。不要複製到文件或聊天中。
RLS（列級安全）	資料庫逐筆檢查「這個身份可以看或改這筆資料嗎」。只把按鈕藏起來不足以保護資料，直接發 API 請求仍須被擋住。
RPC（遠端程序呼叫）	呼叫資料庫內預先寫好的操作，例如固定快照、預留費用。要有執行權限，函式內也須核對角色與狀態。
Transaction / 原子性	一組步驟全部成功才生效，失敗就全部取消。例如 QA 五筆引用只要一筆不合法，不應只存其中三筆。
公開 anon key	舊式 Supabase 公開應用識別值，可放瀏覽器。它不等於管理員身份；使用者登入後的身份與 RLS / RPC 才決定權限。
service_role / secret key	伺服器專用高權限憑證，可能略過 RLS。不可放前端、VITE_*、Git、PDF 或公開 log。Gemini key 同樣只在受控端保存。

例：陌生人拿到網站內的公開 key，仍不能讀 owner 的問答紀錄或任意付費試問；登入 editor 也不能因改前端程式就取得 owner 操作。後端與資料庫必須各自執行限制。

官方依據：Supabase API keys（公開 key 與伺服器 secret 的用途）

Supabase 新版用 publishable key 對應公開用途，舊專案仍可能使用 anon key。本段解釋現行設定，不代表本次已完成 key 遷移或整個專案安全稽核。

16 / TECHNICAL REFERENCE

管理介面與互動紀錄

長列表與詳情分離，讓審閱不必反覆捲到頁尾。

頁面 / 操作	目前使用方式
文件與段落	每頁 12 份，可搜尋。檢視用 native dialog 開在當前視窗；每頁 25 段，換頁回到新頁開頭。匯入及作業進度可展開。
QA / 人格 / 提示詞 / 計算	在獨立詳情視窗編輯。儲存中禁止關閉；取消或關閉會捨棄尚未儲存變更。
知識版本	長來源與品質清單可收合；避免將審核與版本控制推到很遠的位置。
互動紀錄	預設人工試問，每頁 20 筆；卡片顯示問題及回答摘要，可切換自動評測 / 全部新版紀錄。
完整問答與流程	原始問題、回答、引用文件 / 物理頁、逐字摘錄、處理節點、耗時、模型呼叫與費用。讀取不呼叫模型。
鍵盤與手機	Tab 在詳情內循環；Esc 關閉並還原原按鈕焦點與列表位置。手機滿版詳情，標題與關閉鈕固定。

歷史讀取的技術路徑

InteractionHistory → TrialRepository.history → rag_v1_requests + rag_v1_request_details 的 owner 授權投影。列表只取問題、回答摘要所需欄位，以 created_at 與 id 穩定排序，讀 21 筆判斷下一頁、顯示 20 筆。

開啟詳情後，request_read 取得保存的輸出與 trace，另查問句投影與模型費用連結。AbortController、識別碼核對及晚回傳忽略，避免快速切換時顯示錯筆資料。頁面隱藏時解除 modal，既有頁面狀態仍可保留。

> 之前互動紀錄只呈現舊版追蹤，沒有接上 v1 問答正文，現已補齊。舊版未保存的問答無法還原；新版正文與詳細流程超過 30 天後不再顯示，保留狀態及費用語意。

前一輪 2026-10-27 已在真實 Chrome 重開使用者先前送出的 IPCC 問題，可見完整問答、8 個引用與 8 個流程節點。本輪 2026-10-28 桌面 RPC 無法連線，未重新驗證真實登入 / 讀取；僅做本機合成 UI 驗證，沒有新增模型呼叫。

17 / TECHNICAL REFERENCE

成本、配額與保存策略

三種金額分開顯示；未知成本不能填成零。

數字	意義
保守預留	模型連線前原子預留上限，用來守住 campaign / round；不是 Google 扣款。未知結果仍占預留。
用量估算	有可用 provider usage 時依固定單價版本計算；缺 usage 的呼叫保持未知。文件準備成本不重複加到每題。
實際帳單	由管理員匯入真實 Google 使用費 CSV 對帳；預付款與儲值金額不能當成本。

固定計價版本 2026-10-26：embedding US$0.15 / 百萬 tokens；回答 input US$0.25、output US$1.50 / 百萬 tokens。可計費 thoughts 納入 output。此為系統記錄版本，並非即時報價；模型或單價改動應保留新版本。

生成估算 USD = (input_tokens × 0.25 + (output_tokens + thoughts_tokens) × 1.50) / 1,000,000
只在使用量完整、模型呼叫收到回應時使用；缺項不補零。

2026-10-27 07:49 查核快照

項目	已記錄結果
Campaign	US$5 上限；571 次模型呼叫；預留 US$3.65777525；尚餘 US$1.34222475。
使用量完整度	52 次有可用 usage，小計 US$0.05647875；519 次缺 usage。這不是整輪總成本，Google 帳單尚未匯入。
人工輪次	最多 5 題 / US$0.15，已用 1 題；截止 2026-11-02 18:35（臺灣時間），仍受同一 campaign 限制。

輪次最多 100 題；個人 UTC 每日跨輪次上限最多 200 題。評測開始時預留整份題數。停止 campaign 或輪次會阻止後續呼叫，已開始的呼叫仍可能完成。未知請求不自動重送或退額度，不能另建預算規避總上限。

問答正文與詳細 trace 限權保留 30 天，排程每小時做有界清理；帳本保留，清理不恢復花費容量。帳單 CSV 先預覽後確認，限 64 KiB / 20 列，要求 UTC 期間與明確模型，拒絕重疊時段。

18 / TECHNICAL REFERENCE

預留、冪等、租約與留存

名詞	例子與意義
預留（reservation）	模型呼叫前先占一筆安全額度。假設先預留 US$0.02，之後用量估算 US$0.0004，兩者意義不同，不能把預留說成已扣款。
冪等（idempotency）	同一操作識別碼重送，應查到同一結果，避免重複建立或付費。新的識別碼是新操作；重新整理會丟掉前端記憶體 key。
租約（lease）	worker 領工作時暫時取得處理權，帶期限與憑證。到期不表示外部模型未執行，必須先核對狀態。
uncertain（結果不明）	網路中斷或記帳未確認。不能當成零成本、退款或允許自動重跑。
留存（retention）	訂定資料能讀取多久。v1 問答正文與詳細流程 30 天後不可讀，排程每小時有界清理；費用帳與必要識別資訊另保留。

30 天不是「所有資料一律刪光」。原始文件、候選版本和費用帳不因問答詳情過期一起消失；帳本不會因清理而重置額度。長期文件刪除、備份、供應商資料政策與一般 App 使用者隱私流程仍需另定政策。

US$5 是這次受控模型活動的授權上限，不包含未建置的雲端解析主機費、Storage 或流量。Google 預付 600 元是帳戶儲值，不是本活動已花費的模型成本。

19 / TECHNICAL REFERENCE

評測結果與驗收界線

題庫與版本 hash 固定；修正程式不會覆寫歷史分數。

題庫	通過題數	Recall@5	引用有效率
Development	19 / 20	0.875	1.0
Acceptance	36 / 40	0.9375	1.0

兩組在付費執行前固定且問題不重疊。真實評測由受信任本機 worker 執行共用 TypeScript 邏輯，連接 Supabase 與 Gemini。引用有效率只描述已接受回答的機械檢查；不是全部題目答對，也不是語意正確率。確定性計算數值失敗與未發布資料洩漏指標均為 0。

保留失敗	原因與處理
development-01	全量檢索逾時；SQL 已改善，原失敗與費用保留，不退額度、不重跑。
acceptance-11	預期 gold 未進 top 5，也未被引用。
acceptance-12 / 13	英文數量或單位翻譯成中文，不符合逐字契約而拒答。
acceptance-14	跨窗口 PDF 行號去空白被接成數字，造成誤拒。驗收後修正 offset / 原文邊界並加合成測試；分數仍維持 36/40。

工程證據分層

2026-10-27 前端驗證基準：19 檔、104 tests 通過，型別、build 與 audit 通過。UX 合成瀏覽器 5 個寬度 / 15 項檢查通過；完整管理整合 7 組檢查通過。後端既有紀錄：Node 共用邏輯 37 tests、Python 100 tests；SQL rollback fixtures 覆蓋權限、預算與生命週期。 本版 UX / PDF 檢查另見本次收尾單。

真實線上單題由使用者送出，約 11.5 秒完成，2 次模型呼叫均 HTTP 200；8 個處理節點與 8 個引用可重開。這證明該次連線流程可用，不取代固定題庫或人工語意驗收。

發布門檻包含同一版本至少 40 題驗收、Recall@5 至少 90%、引用有效率至少 95%、數值錯誤與越權引用為 0，且需有效人工核准。通過某些門檻不等於全數題目正確，仍須審閱保留失敗。

20 / TECHNICAL REFERENCE

評測與維運名詞速查

名詞	讀報告時怎麼理解
Development / Acceptance	開發題用來找問題與調整；驗收題固定保留作獨立檢查。不要看完驗收結果才改 gold 讓分數變好。
Gold / Recall@5	gold 是人工指定應找到的來源。Recall@5 檢查前五名覆蓋了多少必要來源，不等於整體回答正確率。
引用有效率	程式檢查引用來源與文字是否有效；不能代替「這段原文是否支持這個主張」的人工判斷。
數值失敗 / 越權來源	數字或單位檢查未過，或引用了版本外資料。發布要求這些門檻滿足。
Migration	以版本化 SQL 描述資料庫變更，可追查結構與權限如何演進；不是在介面任意改欄位。
Preview / Production	Preview 是這次受保護的審閱部署；Production 是正式站。推 main 可能部署正式站，需另外授權。
Mock / 回歸測試	Mock 用合成資料驗證 UI，不代表真實模型或登入成功。回歸測試確認修改沒有破壞已知行為。
CI / Build / CSP	CI 自動跑檢查；Build 打包網站；CSP 限制網頁可執行或連接的來源，降低內容注入風險。
p95 / 負載測試	p95 指 95% 請求在該時間內完成。單次測得 11.5 秒不能當作 p95，也不能宣稱可承受大量同時使用者。

報告要同時看版本、題數、失敗例、費用和測試方式。「有答案」「引用通過」「40 題全過」與「人工同意對外使用」並不是同一件事。

21 / TECHNICAL REFERENCE

部署、維運與故障處理

下列是維護程序，不表示本次製作文件重新執行了部署或付費測試。

部署與驗證順序

1. 先檢查 Git 狀態與 commit，確認網站及後端的 Preview 分支。
2. 網站執行下列檢查，確認產物沒有 secrets、原文、私人截圖或測試入口。
3. 只推授權 Preview 分支；保持 Vercel Authentication。後端 migrations / Edge 由後端 repo 管理。
4. 查核部署 SHA 與 URL，再以正常管理員登入，讀既有資料及配額；需試問時才明確提交新請求。

```
npm ci
npm run type-check
npm test
npm run build
npm audit --audit-level=moderate
node scripts/check-release.mjs
node scripts/check-release.mjs --staged
```

情況	處理方式
Google 403 / 429	保留 request ID，查 key 所屬專案、計費、API / 模型權限或配額。不貼金鑰、不連續重送。
逾時或結果未知	先 request_read；未知仍保留費用。超過五分鐘可由 owner 結束為未知，不補發題數。
無證據或被拒答	核對快照來源、門檻、完整脈絡、引用及數值單位原因；改草稿後需建新版本。
URL 憑證失敗	保留失敗紀錄並查來源憑證；不關閉 TLS 驗證。
停止與回復	停止 campaign / round 阻止新模型呼叫。網站可重部署先前 Preview；不能刪帳本或重設預算。知識回滾只選曾發布、仍核准且來源可用的版本。

Windows PowerShell 可使用 npm.cmd / openspec.cmd，避免 ps1 執行政策造成誤判。正式 build 不會自動讀 .env.development.local，應明確供應四個公開 VITE 設定但不印值。推 main 會觸發 Production，需獨立授權。

22 / TECHNICAL REFERENCE

人工驗收與後續工作

目前適合有配額的 owner 線上審閱，尚不是一般使用者上線驗收通過。

審閱項目	人工確認內容
來源與使用權	文件身份、書目、地區、日期與使用範圍；一份論文檔名與內文標題不一致仍需釐清。
解析品質	物理頁、欄名、註腳、負號、上下標、OCR、跨頁表格與研究範圍。頁碼完整不代表語意擷取正確。
回答與引用	逐句核對來源是否支持結論；區分相關性與因果，檢查缺少條件或過度推論。
QA 與計算	直接證據、語氣、係數單位、有效期間、完整級距及不適用情境。
版本及評測	指定 snapshot hash、兩份固定報告、失敗案例、可用預算及資料停用狀態。

未完成或未驗證

人工內容核准、缺字 / OCR / 標題修正及三個 TLS 失敗來源仍待處理。真實知識發布 / 回滾、公開服務啟用尚未執行。Google 帳單尚未對帳；Safari、Firefox、真機與併發負載尚未驗收。Node 離線測試不等於 Deno runtime 完整測試。

建議接續順序

先完成來源與答案人工審閱 → 對問題來源建立新的修訂候選 → 固定新的獨立驗收題庫與有限費用 → 執行跨瀏覽器 / 負載 / 安全缺口檢查 → 決定是否核准並發布指定版本 → 最後規劃 Flutter、一般使用者權限與隱私流程。

> 任何後續修正都保留原始失敗、舊快照及費用紀錄。內容更新、模型 / profile 變更與計價更新需可追溯；不可只為提升分數改 gold、覆寫舊報告或排除未知結果。

本文件的限制與數據截至版本基準時間。未來審核、帳單或配額變更，請以受保護管理介面及最新交接紀錄為準。

23 / TECHNICAL REFERENCE

未來不用本機解析：雲端背景工作

建議把現有 Python / Docling / RapidOCR 包成容器，交由 Cloud Run Jobs 執行。容器把程式與依賴裝在一起；Job 執行一份工作，完成後退出。Supabase 保留身份、私有原檔、工作狀態、版本與預算管理。這是未部署的建議方案。

順序	責任與輸出
1 管理員上傳	登入後上傳私有 Storage，核對格式、20 MiB 上限與 hash。
2 登記工作	後端把 parse 工作寫入持久佇列。成功收到工作 ID 後，不必一直開著瀏覽器。
3 派送 / 領取	驗證身份的派送程式啟動 Job；worker 以工作租約領取，防止同時重複處理。
4 雲端解析	下載指定原檔，檢查 hash，解析 / OCR，逐頁核對，保存段落與品質警示。
5 有限向量化	先核對共用預算，再逐批 embedding；可重用的向量不重付費，未知結果先停下核對。
6 回報與人工審查	畫面讀取進度、失敗原因及 ready 集合；後續固定快照、評測、人工核准維持不變。

上傳成功且工作已登記後，關閉瀏覽器不會讓已交付的雲端工作消失；上傳中就關閉則可能尚未交付。仍需處理雲端失敗、逾時和重啟，不能把「背景工作」當成保證成功。

官方能力參考：Cloud Run Jobs

24 / TECHNICAL REFERENCE

雲端方案還需要完成哪些事

工作	驗收方式
封裝與資源限制	固定 parser / OCR 版本；限制頁數、時間、CPU / 記憶體與同時工作數，使用範例長 PDF 實測。
佇列與狀態	登記後有持久工作 ID；重複通知不重建集合，租約到期可辨識，進度與失敗原因能回報。
憑證與網路	使用受控服務身份及秘密管理；只讓 worker 取得需要的資料，瀏覽器不拿高權限 key。URL 抓取維持網域與公開 IP 檢查。
重試與費用	解析失敗可有界重試；已外呼但未知的 embedding 不自動再付費。預算活動之外另設雲端資源成本監控。
一致性與恢復	雲端產出須保留 hash、物理頁碼、完整表格、parser/profile 及新集合身份；人工審核規則保持一致。

為什麼不直接把長 PDF 解析放進 Supabase Edge Function？它適合身份驗證和短請求編排；官方目前限制記憶體 256 MB、每請求 CPU 2 秒等，與 Docling / OCR 的工作型態不合。建議讓 Edge 登記及派送，再由可配置資源的 worker 處理。

Cloud Run 的運算、記憶體、儲存與流量費用須分開估算。先用數份代表性文件量測時間與資源，再定上限；帳單警示通常是通知，不能當成即時硬停費保證。

官方限制：Supabase Edge Functions

官方價格與計量：Cloud Run

本次僅新增規劃與文件，沒有建立雲端 Job、派送服務、服務帳號或新付費資源。

25 / TECHNICAL REFERENCE

來源索引與版本依據

工程事實以固定程式及專案紀錄為準；官方文件提供介面背景。

專案來源

[R1] 管理介面使用說明：模型、方法、操作、安全與保存

[R2] RAG v1 人工審閱交接：語料、固定評測與費用快照

[R3] 詳情導覽與問答紀錄收尾：最新 UX 與線上讀取證據

[R4] Protected RAG Preview：部署與停止方式

[R5] 後端開發與驗證：本機 CLI、共用邏輯及 SQL 測試

官方技術參考（2026-10-27 / 28 查閱）

[R6] Google Gemini API - Embeddings

[R9] Docling 與 OCR 能力

[R10] RapidOCR 專案文件

[R7] Google Gemini API - Structured outputs

[R8] Supabase - Row Level Security

程式定位

位置	用途
src/push-admin/rag/	UI、repository 介面、問答 / 評測 / 版本與費用顯示；TrialFlow、InteractionHistory、DetailDialog。
supabase/functions/rag-v1/	Edge 入口、權限與模型請求、工具、引用驗證及評測。
supabase/migrations/*rag*.sql	資料結構、RLS / RPC、不可變性、預留、審核、發布與留存。
scripts/rag/	本機盤點、解析、OCR、URL 快照、匯入與 embedding。

原始驗證 log、文件全文、模型診斷與帳號截圖位於忽略的本機 reports 或私有服務，不放入可分享 PDF。PDF 內連結可點選；GitHub 專案權限仍適用。文件內容不取代 migrations、固定快照契約或實際帳單。